

Google DeepMind: 衡量 AGI 进展的认知框架

论文: *Measuring Progress Toward AGI: A Cognitive Framework*

作者: Ryan Burnell, Yumeya Yamamori, Orhan Firat 等 (Google DeepMind)

日期: 2026-03-16

原文链接: [PDF 全文](#)

核心问题

尽管 AGI 讨论广泛，业界至今缺乏一套系统化的衡量框架。传统 benchmark（如 MMLU、BIG-bench）容易被“刷分”，且无法反映模型的真实通用智能水平。DeepMind 基于认知科学、心理学和神经科学数十年的研究积累，提出了一套 **认知分类法（Cognitive Taxonomy）**，将通用智能拆解为 **10 个核心认知能力**，并配套一个三阶段评估协议。

十大认知能力

八项基础能力

#	能力	核心定义
1	感知 (Perception)	从环境中提取和处理感官信息——视觉（从边缘检测到场景理解）、听觉（从音高辨别到语音理解）、以及 AI 独有的文本感知（tokenization 直达语言层）
2	生成 (Generation)	产生输出：文本、语音、动作（机器人控制、计算机操作），以及“思维生成”——即内部推理链以指导决策（类似 o1 风格的 CoT）
3	注意力 (Attention)	将认知资源聚焦于关键信号、过滤噪声，并对环境变化保持敏感
4	学习 (Learning)	通过经验获取新知识——联想学习、强化学习、模仿学习、程序化学习、语言学习等
5	记忆 (Memory)	短期、长期、语义、情景和前瞻性记忆的存储与检索，同时强调 主动遗忘 的重要性
6	推理 (Reasoning)	通过逻辑推断得出有效结论——演绎、归纳、溯因、类比和数学推理

7	元认知 (Metacognition)	“知之为知之，不知为不知”——对自身认知过程的监控与理解，是模型产生幻觉的关键根源
8	执行功能 (Executive Function)	对应 Agent 能力——规划、目标设定、抑制冲动、认知灵活性、反馈调节与冲突解决

两项复合能力

#	能力	核心定义
9	问题解决 (Problem Solving)	综合运用感知、学习、推理、规划等多种基础能力，解决特定领域的具体问题
10	社会认知 (Social Cognition)	理解他人的信念与意图（心智理论），并进行合作、谈判、说服；论文同时指出其在安全层面的双刃剑效应

三阶段评估协议

1. 认知评估：让 AI 完成覆盖全部 10 个能力维度的任务集，难度梯度覆盖从人类轻松到人类极限
2. 采集人类基线：让具有人口统计学代表性的成人样本在相同条件下完成同一任务
3. 构建认知画像：将 AI 表现定位在人类分布中，生成 10 维雷达图——暴露模型的“参差不齐”特征

三种未来情景

情景	描述
A — 参差型	系统在部分维度达到人类中位水平，部分维度明显不足（类似当前 AI 系统）
B — 全面达标型	系统在所有维度均达到或超过人类中位水平，但不一定全面碾压
C — 超人型	系统在几乎所有能力上超过人类顶尖水平

为什么需要新框架？

- 传统 benchmark 容易被训练数据污染，“刷题”不等于真正的通用能力
- 未来评估的对象不只是模型本身，而是**整个系统**——包括 Agent 能力和外部工具调用

- 需要从**模型评估**转向**系统评估**，基于认知维度持续跟踪 AI 能力演进

配套行动：Kaggle 黑客松

DeepMind 联合 Kaggle 发起 20 万美元奖金的黑客松（2026.3.17–4.16），聚焦当前评估缺口最大的五个能力：**学习、元认知、注意力、执行功能、社会认知**。

Elite 20 同学们——这是你们的机会！

这次 Kaggle 黑客松与我们的 Elite 20 课程深度绑定，分为两个阶段：

第一阶段：C2A 选拔提案（截止 4/9）

在 **4 月 9 日**前提交一份 Kaggle 参赛方案提案，内容包括：

- 选择的赛道（五选一：Learning / Metacognition / Attention / Executive Functions / Social Cognition）
- 你计划设计的 benchmark 思路与创新点
- 为什么这个评估方案能有效测量该认知能力

 这份提案将作为 Elite 20 录取评审的一部分——展示你对认知科学和 AI 评估的理解深度。

第二阶段：C9 正式提交（4/10–4/16）

通过选拔的同学将在 **4 月 10 日至 16 日**期间完成 Kaggle 正式提交，作为 **C9 课程作业**。你的作品将在 Kaggle Community Benchmarks 平台上直接对前沿模型进行测试，成果可能被 DeepMind 纳入正式评估体系。

为什么一定要参加？

- **与课程直接相关**：我们在 AI+X 课程中学习的 KSTAR 认知循环、Agent 架构、元认知机制，与这五个赛道高度契合
- **实战即学习**：为 AGI 设计评估任务本身就是对认知科学的深度理解——这比任何作业都更有价值
- **全球舞台**：与全球顶尖 AI 研究者同台竞技
- **奖金丰厚**：单赛道前两名各 \$10,000，总冠军 \$25,000

行动建议：2-3 人一组，推荐从 *Learning* 或 *Metacognition* 赛道入手——这两个方向与我们课上学到的 KSTAR 认知架构最为对口。有想法的同学请尽快联系我，我们可以一起讨论方案。

 比赛入口：[Kaggle - Measuring Progress Toward AGI](#)

一句话总结: DeepMind 用认知科学为 AGI 画了一张“体检表”——10 个维度的雷达图，比单一分数更诚实地暴露 AI 系统“哪里强、哪里脆”。